

Calcolo numerico

Trascrizione degli appunti

Legenda

1. Numeri macchina

- Rappresentazione numerica
- Distanza
- Underflow
- Overflow
- Troncamento
- Arrotondamento
- Operazioni tra numeri macchina
- Proprietà operazioni macchina

2. Equazioni non lineari

- Th. degli zeri
- Metodo di bisezione
- Metodo della falsa posizione
- Metodi di iterazione funzionale
- Interpretazione geometrica
- Convergenza locale
- Criterio di stop
- Ordine di convergenza
- Metodo di Newton-Raphson
- Th. convergenza
- Molteplicità di una radice
- Metodo della direzione costante
- Metodo della secante

3. Sistemi di equazioni lineari

- Regola di Cramer
- Metodo di eliminazione di Gauss
- Strategie di pivoting
- Pivoting parziale
- Pivoting totale
- Fattorizzazione LU
- Equivalenza tra Gauss e LU
- Condizionamento sistemi lineari

4. Interpolazione

- Interpolazione polinomiale
- Polinomio interpolante di Lagrange
- Errori di interpolazione
- Th. di rappresentazione dell'errore di interpolazione
- Fenomeno di Runge
- Minimizzare il resto nel problema di interpolazione
- Polinomio di Chebyshev
- Th. di Minimax
- Funzioni spline
- Approssimazione ai minimi quadrati
- Retta di regressione

5. Quadratura

- Formule di quadratura di tipo interpolatorio
- Grado di precisione
- Formula di Newton-Cotes
- Formula dei Trapezi
- Resto nella formula dei trapezi
- Th. della media generalizzato
- Formula di Simpson
- Formula del punto di mezzo
- Formule di quadratura composta
- Formula dei trapezi composta
- Formula di Simpson composta
- Formula del punto di mezzo composta

6. Derivazione numerica

- Differenze in avanti
- Differenze all'indietro

7. Eq. differenziali

- Metodo di Eulero esplicito
- Metodo di Eulero implicito
- Metodo dei trapezi
- Metodo del midpoint
- Classificazione metodi numerici
- Studio della convergenza

1 Numeri macchina

Il calcolo numerico è una branca della matematica che cerca di risolvere problemi matematici utilizzando uno o più algoritmi. Il computer ha una memoria finita e questo porta ad approssimazioni di numeri e risultati. Le approssimazioni sono sinonimi di errore. Gli errori possono essere analitici (dovuti all'esigenza di calcolare sommatorie infinite in un tempo finito) o di rappresentazione (dovuti all'esigenza di rappresentare un numero con infinite cifre in una memoria finita). È possibile misurare l'errore in due modi:

$$e_A(x) = \|x - \tilde{x}\|, \quad e_R(x) = \frac{\|x - \tilde{x}\|}{\|x\|}, \quad x \neq 0.$$

Rappresentazione numerica

Rappresentare $\mathbb{R}$ diventa impossibile. Viene utilizzato un insieme $\mathbb{F}$ dei floating point numbers. Si utilizza la rappresentazione normalizzata, cioè parte intera nulla e prima cifra dopo la virgola non nulla:

$$x = (-1)^s 0.d_1 d_2 \cdots d_t \beta^E, \quad d_1 \neq 0.$$

$$\mathbb{F}(\beta, t, m, M) = \{x \in \mathbb{R} : x = (-1)^s 0.d_1 \cdots d_t \beta^E\} \cup \{0\},$$

con $t \geq 1$, $\beta \geq 2$, $m, M > 0$, $d_1 \neq 0$, $d_i \in \{0, \dots, \beta - 1\}$, $E \in [-m, M]$. β è la base, t il numero di cifre della mantissa, m il valore assoluto dell'esponente minimo, M l'esponente massimo.

Un bit per il segno s , t bit per la mantissa $(d_1, \dots, d_t)$, $M + m + 1$ combinazioni per l'esponente E . I numeri macchina hanno varie proprietà: $\mathbb{F}$ è discreto; i numeri rappresentabili sono solo una piccola parte di $\mathbb{R}$; la distanza tra due numeri consecutivi non è costante.

$$x_i = \beta^E 0.d_1 \cdots d_{t-1} d_t, \quad x_{i+1} = \beta^E 0.d_1 \cdots d_{t-1} \tilde{d}_t, \quad \tilde{d}_t = d_t + 1.$$

La distanza è $x_{i+1} - x_i = \beta^E 0.00 \cdots 1 = \beta^{E-t}$. Per $E = -m$ vale β^{-m-t} ; per $E = M$ vale β^{M-t} . Il rapporto tra le distanze è β^{M+m} (enorme).

Underflow e overflow

Ci sono numeri troppo vicini allo zero per essere rappresentati e numeri troppo grandi. Se

$$x = \pm \beta^E \sum_{i=1}^n d_i \beta^{-i}, \quad n \leq t, \quad E < -m,$$

il numero è più piccolo del più piccolo elemento positivo di $\mathbb{F}$ e si verifica underflow.

Se $x < \min \mathbb{F}^+$, x sarà calcolato come zero. Se $x = \pm \beta^E \sum_{i=1}^n d_i \beta^{-i}$, $n \leq t$, $E > M$, il numero è più grande del massimo elemento di $\mathbb{F}$ e si verifica overflow. Se $x > \max \mathbb{F}$, x sarà considerato Inf.

Troncamento e arrotondamento

Se $n > t$, bisognerà troncare il numero per poterlo rappresentare:

$$\tilde{x} = \text{tr}(x) = \pm \beta^E \sum_{i=1}^t d_i \beta^{-i},$$

$$\hat{x} = \text{arr}(x) = \pm \left(\beta^E \sum_{i=1}^t d_i \beta^{-i} + \Omega \beta^{E-t} \right), \quad \Omega = \begin{cases} 0 & d_{t+1} < \beta/2, \\ 1 & d_{t+1} \geq \beta/2. \end{cases}$$

Se $x \notin \mathbb{F}$, esistono $a, b \in \mathbb{F}$ tali che $a \leq x \leq b$. Se $x < (a+b)/2$, $a = \text{tr}(x) = \text{arr}(x)$; se $x \geq (a+b)/2$, $a = \text{tr}(x)$ e $b = \text{arr}(x)$. L'arrotondamento può portare all'overflow, anche all'underflow. Se $d_i = \beta - 1$ per ogni $i = 1, \dots, t$, $E = M$ e $d_{t+1} \geq \beta/2$, allora $\text{arr}(x) = \pm \beta^M = \pm 0.1 \beta^{M+1}$. Troncamento e arrotondamento producono errori.

Calcoliamo l'errore di trasformazione:

$$|\mathrm{tr}(x) - x| < b - a = \beta^{E-t}, \quad |x| = \beta^E 0.d_1 \cdots d_t \geq \beta^{E-1}.$$

$$e_R(x) = \frac{|x - \mathrm{tr}(x)|}{|x|} \leq \beta^{1-t}.$$

$$|\mathrm{arr}(x) - x| \leq \frac{1}{2}(b - a) = \frac{1}{2}\beta^{E-t}, \quad e_R(x) \leq \frac{1}{2}\beta^{1-t}.$$

I numeri $u < \beta^{1-t}$ sono detti zero macchina per il troncamento ($u < \frac{1}{2}\beta^{1-t}$ per l'arrotondamento). Posto $\varepsilon_x = (\tilde{x} - x)/x$, con $|\varepsilon_x| \leq u$, segue $\tilde{x} = x(1 + \varepsilon_x)$. È la relazione tra $x \in \mathbb{R}$ e $\tilde{x} = \mathrm{fl}(x) \in \mathbb{F}$.

Operazioni tra numeri macchina

$x, y \in \mathbb{F}$ non implica $x \cdot y \in \mathbb{F}$. L'operazione macchina soddisfa

$$x \odot y = (x \cdot y)(1 + \varepsilon), \quad |\varepsilon| < u. \quad (1)$$

$x \cdot y = x \odot y$ se e solo se $\varepsilon = 0$. Le operazioni $\mathrm{tr}(x \cdot y)$ o $\mathrm{arr}(x \cdot y)$ soddisfano (1). Ogni operazione ha un metodo per essere effettuata correttamente.

Addizione e sottrazione (somma algebrica)

Siano $x, y \in \mathbb{F}(\beta, t, m, M)$. I passaggi sono:

1. Prendere l'esponente maggiore e modificare il numero con esponente minore affinché $E_y = E_x$.
2. Sommare le mantisse.
3. Normalizzare la somma delle mantisse.
4. Arrotondare o troncare il risultato.

Esempio: $x = 0.78546 \cdot 10^2$, $y = 0.61332 \cdot 10^{-1}$, $\tilde{y} = 0.00061 \cdot 10^2$, $x \oplus y = 0.78607 \cdot 10^2$. Esempio: $x \simeq y$, $x = 0.75868531 \cdot 10^2$, $y = 0.75868100 \cdot 10^2$. $\tilde{x} = 0.75869 \cdot 10^2$, $\tilde{y} = 0.75868 \cdot 10^2$.

$$\text{fl}(\tilde{x} - \tilde{y}) = 0.00001 \cdot 10^2 = 0.1 \cdot 10^{-2},$$

$$x - y = 0.00000431 \cdot 10^2 = 4.31 \cdot 10^{-4} = 0.0431 \cdot 10^{-2}.$$

$$e_R(x - y) = \frac{|\text{fl}(\tilde{x} - \tilde{y}) - (x - y)|}{|x - y|} \simeq 1.32.$$

Errore molto elevato: cancellazione numerica di cifre significative quando $x \simeq y$.

La cancellazione numerica di cifre significative rappresenta un caso di problema mal condizionato.

Prodotto

$$x \odot y = \text{arr}(\text{mantissa}(x) \text{ mantissa}(y)) \beta^{E_x + E_y}.$$

I passaggi: eseguire il prodotto delle mantisse; arrotondare/troncare le t cifre dopo aver normalizzato; moltiplicare per $\beta^{E_x + E_y}$ (sommare gli esponenti). Esempio: $x = 0.11111 \cdot 10^3$, $y = 0.52521 \cdot 10^2$:

$$0.11111 \cdot 0.52521 = 0.05835608 \simeq 0.58356 \cdot 10^{-1}, \quad x \odot y = 0.58356 \cdot 10^4.$$

Divisione

Scalare l'esponente di x affinché $\text{mantissa}(x) < \text{mantissa}(y)$; dividere le mantisse; normalizzare e arrotondare/troncare; sottrarre gli esponenti. Esempio: $x = 0.12100 \cdot 10^5$, $y = 0.11000 \cdot 10^2$, $\tilde{x} = 0.01210 \cdot 10^6$. Il rapporto delle mantisse è 0.11000 e $x \oslash y = 0.11000 \cdot 10^{6-2} = 0.11000 \cdot 10^4$.

Proprietà delle operazioni macchina

1. $\mathbb{F}$ non è chiuso rispetto alle operazioni macchina (a causa dell'underflow).
2. L'elemento neutro per la somma non è unico: numeri molto piccoli vengono considerati zero.
3. L'elemento neutro per il prodotto non è unico: numeri molto vicini a uno.
4. Non vale l'associatività di somma e prodotto: $(a + b) + c \neq a + (b + c)$.
5. Non vale la distributività: $a(b + c) \neq ab + ac$.

Condizionamento dei problemi

Un problema si dice ben condizionato se a piccoli errori sui dati corrispondono piccoli errori sui risultati. È mal condizionato se non è ben condizionato. Il condizionamento è una caratteristica intrinseca del problema e non dipende dal metodo di risoluzione adottato. Un problema mal condizionato va sostituito con uno meglio condizionato tramite tecniche di preconditionamento.

2 Equazioni non lineari

Teorema degli zeri

Sia $f : [a, b] \rightarrow \mathbb{R}$, $f \in C([a, b])$, $f(a)f(b) < 0$. Allora esiste $c \in (a, b)$ tale che $f(c) = 0$.

Metodo di bisezione

Si costruisce una successione di intervalli $\{I_k\}_{k=0}^\infty$ tale che $I_0 = [a, b]$, $I_{n+1} \subset I_n$, $\alpha \in I_n$ per ogni $n \geq 0$ e $|I_k| \rightarrow 0$ per $k \rightarrow \infty$. $I_0 = [a_0, b_0]$, $c_1 = (a_0 + b_0)/2$. Se $f(a)f(c) < 0$, $a_1 = a_0$, $b_1 = c_1$; se $f(c)f(b) < 0$, $a_1 = c_1$, $b_1 = b_0$. In generale

$$c_{k+1} = \frac{a_k + b_k}{2}.$$

Se $f(c_k) = 0$, $c_k = \alpha$, zero di f . A causa degli errori di arrotondamento la condizione $f(c_k) = 0$ non viene quasi mai verificata. Bisogna stabilire un criterio di stop, per esempio $b_k - a_k \leq \varepsilon$, con tolleranza prefissata.

Scelta una tolleranza prefissata, si può dedurre il numero di passi:

$$b_k - a_k = \frac{b_0 - a_0}{2^k} \leq \varepsilon \implies k \geq \log_2 \frac{b_0 - a_0}{\varepsilon}.$$

Se $0 \notin [a, b]$, un altro criterio è

$$\frac{b_k - a_k}{\min(|a_k|, |b_k|)} \leq \varepsilon \quad (\text{errore relativo}),$$

mentre $b_k - a_k \leq \varepsilon$ controlla l'errore assoluto. Un altro criterio potrebbe essere $|f(c_k)| \leq \varepsilon$.

Metodo della falsa posizione

La retta secante è

$$y = f(a) + \frac{f(b) - f(a)}{b - a}(x - a).$$

Ponendo $y = 0$ si ottiene

$$c_1 = a - f(a) \frac{b - a}{f(b) - f(a)}.$$

Se $f(a_0)f(c_1) < 0$ si pone $a_1 = a_0, b_1 = c_1$; se $f(a_0)f(c_1) > 0$, $a_1 = c_1, b_1 = b_0$. Il metodo è uguale alla bisezione, ma cambia il calcolo di c_k . Entrambi hanno vantaggi e svantaggi.

Vantaggi: richiedono esclusivamente la continuità di f ; possono ricavare buone approssimazioni di α , usabili come starting point per metodi iterativi. Svantaggi: convergenza lenta (una cifra di precisione in base due per passo); velocità di convergenza indipendente da f .

Metodi di iterazione funzionale

Sono metodi $x_{k+1} = g(x_k)$, $k = 0, 1, \dots$, dove x_0 è uno starting point. Ogni punto α tale che $g(\alpha) = \alpha$ è un punto fisso di g ; g è detta funzione iteratrice. Per trovare gli zeri di una funzione si può definire

$$g(x) = x - \frac{f(x)}{h(x)}, \quad h : [a, b] \rightarrow \mathbb{R} \setminus \{0\}.$$

Infatti $g(\alpha) = \alpha - f(\alpha)/h(\alpha) = \alpha$ se e solo se $f(\alpha) = 0$. **Teorema.** Se $g \in C([a, b])$, la successione $x_{k+1} = g(x_k)$ è contenuta in $[a, b]$ e converge, il suo limite α soddisfa $g(\alpha) = \alpha$. *Dimostrazione.* $\alpha = \lim x_{k+1} = \lim g(x_k) = g(\lim x_k) = g(\alpha)$.

Questa è una condizione necessaria ma non sufficiente. **Teorema (condizione sufficiente).** Sia α punto fisso e $g \in C^1([\alpha - \rho, \alpha + \rho])$, $\rho > 0$. Se $|g'(x)| < 1$ su tale intervallo, allora: per ogni x_0 nell'intervallo, anche tutti gli x_k vi appartengono; $x_k \rightarrow \alpha$; α è l'unico punto fisso nell'intervallo. La condizione garantisce unicità, convergenza e permanenza nell'intervallo.

Interpretazione geometrica

Si alternano il grafico $y = g(x)$ e la retta $y = x$: $x_1 = g(x_0)$, $x_2 = g(x_1)$, eccetera. Nel caso rappresentato $g'(x) \in (-1, 0)$ e gli iterati oscillano attorno al punto fisso.

Convergenza locale

Un metodo iterativo è localmente convergente per $\bar{\alpha} = g(\bar{\alpha})$ se esiste $[a, b]$ tale che per ogni $x_0 \in [a, b]$ la successione converge a $\bar{\alpha}$. Spostando anche di poco x_0 si potrebbe trovare un punto fisso diverso o non trovarne alcuno.

Criteri di stop

$e_k(\alpha) = |\alpha - x_k| < \varepsilon$ non è verificabile, non conoscendo α . Criteri validi possono essere

$$|x_{k+1} - x_k| \leq \varepsilon, \quad \frac{|x_{k+1} - x_k|}{\min(|x_{k+1}|, |x_k|)} \leq \varepsilon, \quad |f(x_k)| \leq \varepsilon.$$

Ordine di convergenza

Sia $x_k \rightarrow \alpha$, $x_k \neq \alpha$ per ogni k . Se esiste $p \geq 1$ tale che

$$\lim_{k \rightarrow \infty} \frac{|x_{k+1} - \alpha|}{|x_k - \alpha|^p} = \gamma,$$

con $0 \leq \gamma \leq 1$ per $p = 1$ e $\gamma > 0$ per $p > 1$, la successione ha ordine p e γ è la costante asintotica di convergenza. Per $p = 1$, $\gamma \in (0, 1)$, la convergenza è lineare; $p > 1$ superlineare; $p = 2$ quadratica; $p = 3$ cubica. Esiste $\beta \simeq \gamma$ tale che

$$|x_{k+1} - \alpha| \leq \beta |x_k - \alpha|^p, \quad \frac{|x_{k+1} - \alpha|}{|\alpha|} \leq \beta |\alpha|^{p-1} \left| \frac{x_k - \alpha}{\alpha} \right|^p.$$

Quindi $e_{k+1}^A \leq \beta (e_k^A)^p$ ed $e_{k+1}^R \leq \beta |\alpha|^{p-1} (e_k^R)^p$.

Teorema. Per $x_{k+1} = g(x_k) \rightarrow \alpha = g(\alpha)$, $g \in C^{p+1}(I(\alpha, \rho))$, l'ordine è $p \geq 1$ se e solo se

$$g'(\alpha) = \dots = g^{(p-1)}(\alpha) = 0, \quad g^{(p)}(\alpha) \neq 0, \quad \gamma = \frac{|g^{(p)}(\alpha)|}{p!}.$$

Metodo di Newton–Raphson

È chiamato metodo delle tangenti; richiede $f \in C^1([a, b])$. La tangente in x_k è $y - f(x_k) = f'(x_k)(x - x_k)$. Ponendo $y = 0$:

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}.$$

Si tratta della precedente iterazione con $h(x) = f'(x)$. **Teorema di convergenza.** Sia $f \in C^3([a, b])$, $f'(x) \neq 0$ per ogni $x \in [a, b]$, $\alpha \in [a, b]$ zero di f . Esiste $[\alpha - \rho, \alpha + \rho]$ tale che ogni iterazione iniziata al suo interno converge ad α , con ordine $p \geq 2$.

Dimostrazione.

$$g'(x) = 1 - \frac{[f'(x)]^2 - f(x)f''(x)}{[f'(x)]^2} = \frac{f(x)f''(x)}{[f'(x)]^2}.$$

Poiché $f'(\alpha) \neq 0$, $g'(\alpha) = 0$, quindi $p \geq 2$ e $|g'(x)| < 1$ in un intorno.

$$g''(x) = \frac{[f'(x)f''(x) + f(x)f'''(x)][f'(x)]^2 - 2f(x)f'(x)[f''(x)]^2}{[f'(x)]^4}.$$

$$g''(\alpha) = \frac{f''(\alpha)}{f'(\alpha)}.$$

Quindi $p = 2$ se $f''(\alpha) \neq 0$, $p \geq 3$ se $f''(\alpha) = 0$. Se $p = 2$, $\gamma = \frac{1}{2}|f''(\alpha)/f'(\alpha)|$.

Molteplicità di una radice

Sia $f \in C^r([a, b])$, $r \in \mathbb{N}$, $r > 0$. Una radice ha molteplicità r se

$$\lim_{x \rightarrow \alpha} \frac{f(x)}{(x - \alpha)^r} = \gamma, \quad \gamma \neq 0, \quad \gamma \neq \pm\infty.$$

Allora $f(\alpha) = f'(\alpha) = \dots = f^{(r-1)}(\alpha) = 0$, $f^{(r)}(\alpha) \neq 0$. Se $r > 1$, $f'(\alpha) = 0$ e Newton ha ordine $p = 1$.

$$f(x) = q(x)(x - \alpha)^r, \quad q(\alpha) \neq 0, \quad g(x) = x - \frac{q(x)(x - \alpha)}{rq(x) + q'(x)(x - \alpha)}.$$

$g'(\alpha) = 1 - 1/r$. Se $r > 1$, $|g'(\alpha)| < 1$, il metodo converge ma l'ordine è uno. Conoscendo la molteplicità si modifica Newton:

$$x_{k+1} = x_k - r \frac{f(x_k)}{f'(x_k)}.$$

Ora $g'(\alpha) = 1 - r/r = 0$, quindi l'ordine torna $p \geq 2$.

Metodo della direzione costante

Se f' si mantiene sensibilmente costante, si pone $M = f'(x_k)$ e si itera

$$x_{k+1} = x_k - \frac{f(x_k)}{M}.$$

Converge se $|g'(x)| = |1 - f'(x)/M| < 1$; quindi $f'(x)$ e M devono avere lo stesso segno.

Metodo della secante

$$x_{k+1} = x_k - f(x_k) \frac{x_k - c}{f(x_k) - f(c)}, \quad c \in [a, b], \quad g(x) = x - f(x) \frac{x - c}{f(x) - f(c)}.$$

3 Sistemi di equazioni lineari

Risolvere un sistema lineare significa trovare un vettore soluzione $\bar{x} \in \mathbb{R}^n$:

$$A\bar{x} = \bar{b}, \quad A \in \mathbb{R}^{n \times n}, \quad \bar{b} \in \mathbb{R}^n.$$

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1, \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2, \\ \cdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n. \end{cases}$$

Determinante

Per $A \in \mathbb{R}^{1 \times 1}$, $|A| = a_{11}$. Regola di Laplace:

$$|A| = \sum_{j=1}^n a_{ij}(-1)^{i+j}|A_{ij}|,$$

dove A_{ij} è il minore complementare. Proprietà: $|I| = 1$, $|A^T| = |A|$, $|AB| = |A||B|$ (Binet), $|\alpha A| = \alpha^n |A|$. Il determinante è zero se una riga o colonna è combinazione lineare delle altre. Una matrice è singolare se $|A| = 0$.

$$|A^{-1}| = 1/|A|, \quad A^{-1}A = AA^{-1} = I_n.$$

Una matrice quadrata singolare non presenta soluzione unica: alcune equazioni dipendono dalle altre e il numero di incognite supera quello delle equazioni indipendenti.

Regola di Cramer

$$x_i = \frac{|A_i|}{|A|}, \quad i = 1, \dots, n,$$

dove A_i è ottenuta sostituendo la colonna i con $\bar{b}$. Per calcolare la soluzione occorrono $n + 1$ determinanti. Indicando con $f(n)$ il numero di operazioni per un determinante di ordine n , $f(1) = 0$, $f(2) = 3$ e, per Laplace,

$$f(n) = nf(n-1) + 2n - 1.$$

Il primo termine conta n determinanti di ordine $n-1$, il secondo n prodotti e $n-1$ somme. Semplificando $f(n) \simeq nf(n-1)$:

$$f(n) = n(n-1) \cdots 3f(2) = \frac{n!}{2} 3 = \frac{3}{2}n!.$$

Per la soluzione occorrono quindi circa $\frac{3}{2}(n+1)!$ operazioni: numero enorme.

Risolvere sistemi triangolari è decisamente più semplice ed efficiente. Per A triangolare superiore si usa sostituzione all'indietro:

$$x_n = \frac{b_n}{a_{nn}}, \quad x_i = \frac{b_i - \sum_{j=i+1}^n a_{ij}x_j}{a_{ii}}, \quad i = n-1, \dots, 1.$$

Per A triangolare inferiore si usa sostituzione in avanti:

$$x_1 = \frac{b_1}{a_{11}}, \quad x_i = \frac{b_i - \sum_{j=1}^{i-1} a_{ij}x_j}{a_{ii}}, \quad i = 2, \dots, n.$$

Il costo computazionale dei due metodi è equivalente:

$$C(n) = \sum_{i=1}^n (2i-1) = 2 \sum_{i=1}^n i - \sum_{i=1}^n 1 = n^2.$$

Trovare la soluzione in una matrice triangolare è meno costoso ($n^2 \ll n!$ per n grande). Si può trasformare A in una matrice triangolare e applicare la sostituzione.

Metodo di eliminazione di Gauss

Due sistemi sono equivalenti se ammettono le stesse soluzioni. Sommando a un'equazione un'altra equazione, o una combinazione lineare delle altre righe, il sistema resta equivalente. Su questo principio si basa Gauss. Si pone $A^{(1)} = A$, $b^{(1)} = b$ e si azzerava $a_{21}^{(1)}$ tramite il moltiplicatore $\ell_{21} = -a_{21}/a_{11}$. Sommando alla riga i la prima riga moltiplicata per ℓ_{i1} si elimina l'elemento a_{i1} . Si calcolano $\ell_{21}, \ell_{31}, \dots, \ell_{n1}$ e si ottengono $A^{(2)}, b^{(2)}$, con prima colonna nulla sotto a_{11} . Poi si calcolano $\ell_{32}, \ell_{42}, \dots, \ell_{n2}$ per ottenere $A^{(3)}$.

Si procede fino ad $A^{(n)}$, triangolare. Per descrivere l'algoritmo, si parte da

$$a_{11}^{(1)}x_1 + \sum_{j=2}^n a_{1j}^{(1)}x_j = b_1^{(1)}, \quad a_{i1}^{(1)}x_1 + \sum_{j=2}^n a_{ij}^{(1)}x_j = b_i^{(1)}.$$

Moltiplicando la prima per $\ell_{i1} = -a_{i1}/a_{11}$ e sommando alla seconda:

$$\sum_{j=2}^n \left(a_{ij}^{(1)} - \frac{a_{i1}^{(1)}}{a_{11}^{(1)}} a_{1j}^{(1)} \right) x_j = b_i^{(1)} - \frac{a_{i1}^{(1)}}{a_{11}^{(1)}} b_1^{(1)}.$$

La prima equazione resta invariata e, per $i, j \geq 2$,

$$a_{ij}^{(2)} = a_{ij}^{(1)} - \frac{a_{i1}^{(1)}}{a_{11}^{(1)}} a_{1j}^{(1)}, \quad b_i^{(2)} = b_i^{(1)} - \frac{a_{i1}^{(1)}}{a_{11}^{(1)}} b_1^{(1)}.$$

Ripetendo dalla seconda equazione, si moltiplica per $\ell_{i2} = -a_{i2}^{(2)}/a_{22}^{(2)}$ per eliminare x_2 .

$$\sum_{j=3}^n \left(a_{ij}^{(2)} - a_{2j}^{(2)} \frac{a_{i2}^{(2)}}{a_{22}^{(2)}} \right) x_j = b_i^{(2)} - b_2^{(2)} \frac{a_{i2}^{(2)}}{a_{22}^{(2)}}, \quad i = 3, \dots, n.$$

La seconda equazione resta invariata. Procedendo, la formula generale è

$$a_{ij}^{(k+1)} = a_{ij}^{(k)} - a_{kj}^{(k)} \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}, \quad b_i^{(k+1)} = b_i^{(k)} - b_k^{(k)} \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}.$$

Limitazione: il moltiplicatore può essere calcolato solo se il pivot $a_{kk}^{(k)} \neq 0$. Un pivot nullo impedisce di proseguire; il pivoting evita il problema. Il costo si calcola in quattro fasi: costo di aggiornamento di un a_{ij}, b_i ; costo per $A^{(k)}, b^{(k)}$; costo da $A^{(1)}$ ad $A^{(n)}$; costo di soluzione triangolare n^2 . L'aggiornamento di a_{ij} richiede tre operazioni, quello di b_i due, essendo già calcolato il rapporto.

Vi sono $(n-k)^2$ coefficienti e $n-k$ termini noti da aggiornare. Al passo k il costo è $2(n-k)^2+3(n-k)$ (il rapporto comune è calcolato una volta per riga).

$$f(n) = 2 \sum_{k=1}^{n-1} (n-k)^2 + 3 \sum_{k=1}^{n-1} (n-k).$$

Usando $\sum_{i=1}^n i^2 = n(n+1)(2n+1)/6$:

$$f(n) = \frac{(n-1)n(2n-1)}{3} + \frac{3n(n-1)}{2} \simeq \frac{2}{3}n^3.$$

Nota di trascrizione: i passaggi algebrici intermedi manoscritti presentano cancellature; il valore finale è $\frac{2}{3}n^3$. Sommando il costo n^2 della sostituzione, la complessità è $O(n^3)$.

Strategie di pivoting

Servono a evitare pivot nulli e l'interruzione di Gauss.

Il pivoting si basa su due teoremi: scambiare due righe non cambia essenzialmente il sistema; in una riga vi è sempre un elemento non nullo se $|A| \neq 0$.

Pivoting parziale

Al passo k si scambia la riga k con una riga $r \geq k$ tale che

$$|a_{rk}^{(k)}| = \max_{i=k, \dots, n} |a_{ik}^{(k)}|.$$

Pivoting totale

Si scambiano righe e colonne: riga k con $r \geq k$, colonna k con $s \geq k$, scegliendo

$$|a_{rs}^{(k)}| = \max_{i,j=k, \dots, n} |a_{ij}^{(k)}|.$$

Il pivot non è molto piccolo e i moltiplicatori non sono grandi. Il costo aggiuntivo consiste nella memorizzazione degli scambi di colonne.

Fattorizzazione LU

Con Gauss, cambiando b occorre rifare tutto il procedimento. Nella fattorizzazione LU si cercano L triangolare inferiore e U superiore, $A = LU$.

$Ax = b$ diventa $LUx = b$. Posto $Ux = y$, si risolve $Ly = b$, poi $Ux = y$. Cambiando b cambia la soluzione del sistema con L , mentre i fattori restano gli stessi. Ponendo $\ell_{ii} = 1$, si impone

$$a_{ij} = \sum_{k=1}^n \ell_{ik} u_{kj} = \sum_{k=1}^{\min(i,j)} \ell_{ik} u_{kj}.$$

Se $i \leq j$:

$$a_{ij} = \sum_{k=1}^{i-1} \ell_{ik} u_{kj} + u_{ij}, \quad u_{ij} = a_{ij} - \sum_{k=1}^{i-1} \ell_{ik} u_{kj}, \quad u_{1j} = a_{1j}.$$

Se $j \leq i$:

$$a_{ij} = \sum_{k=1}^{j-1} \ell_{ik} u_{kj} + \ell_{ij} u_{jj}, \quad \ell_{ij} = \frac{a_{ij} - \sum_{k=1}^{j-1} \ell_{ik} u_{kj}}{u_{jj}}.$$

Esistono due tecniche per calcolare L e U : tecnica di Crout e tecnica di Doolittle.

Crout

			1	
			3	
	2		5	
		4	6	7

Doolittle

			1	
	2		3	
		4	5	
			6	7

Passo	Crout	Doolittle
1	riga 1 di U	riga 1 di U
2	riga 2 di L	colonna 1 di L
3	riga 2 di U	riga 2 di U
4	riga 3 di L	colonna 2 di L
5	riga 3 di U	riga 3 di U
	$\vdots$	$\vdots$

La matrice U coincide con $A^{(n)}$, mentre in L avremo i moltiplicatori. Nella tecnica di fattorizzazione LU non è semplice trovare una strategia di pivoting.

Equivalenza tra Gauss e fattorizzazione LU

$$A\bar{x} = \bar{b} \implies A^{(1)}\bar{x} = \bar{b}^{(1)}.$$

$$L^{(1)} = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ \ell_{21} & 1 & \cdots & 0 \\ \vdots & & \ddots & \vdots \\ \ell_{n1} & 0 & \cdots & 1 \end{pmatrix}, \quad A^{(2)} = L^{(1)}A^{(1)}, \quad \bar{b}^{(2)} = L^{(1)}\bar{b}^{(1)}.$$

Si dimostra in generale che $L^{(k)}A^{(k)} = A^{(k+1)}$ e $L^{(k)}\bar{b}^{(k)} = \bar{b}^{(k+1)}$, con $L^{(k)}$ uguale all'identità salvo la colonna k , che sotto la diagonale contiene $\ell_{k+1,k}, \dots, \ell_{nk}$.

$$A^{(n)} = L^{(n-1)}A^{(n-1)} = L^{(n-1)}L^{(n-2)} \dots L^{(1)}A^{(1)}, \quad \bar{b}^{(n)} = L^{(n-1)}\bar{b}^{(n-1)}.$$

L'inversa $(L^{(k)})^{-1}$ contiene $-\ell_{ik}$ al posto di ℓ_{ik} .

$$L = (L^{(1)})^{-1}(L^{(2)})^{-1} \dots (L^{(n-1)})^{-1}.$$

$$(L^{(1)})^{-1} \dots (L^{(n-1)})^{-1} = (L^{(n-1)} \dots L^{(1)})^{-1} = L.$$

$$\underbrace{(L^{(1)})^{-1} \dots (L^{(n-1)})^{-1}}_L A^{(n)} = A, \quad A^{(n)} = U \implies LU = A.$$

$$L = \begin{pmatrix} 1 & 0 & 0 & 0 \\ -\ell_{21} & 1 & 0 & 0 \\ -\ell_{31} & -\ell_{32} & 1 & 0 \\ -\ell_{41} & -\ell_{42} & -\ell_{43} & 1 \end{pmatrix}, \quad U = A^{(n)}.$$

Condizionamento di sistemi lineari

$$\begin{cases} x + y = 2 \\ 1000x + 1001y = 2001 \end{cases} \implies x = y = 1.$$

Perturbiamo x dell'1%: $\tilde{x} = x(1 + 0.01)$.

$$\begin{cases} 1.01x + y = 2 \\ 1000x + 1001y = 2001 \end{cases} \implies \tilde{x} = -\frac{1}{9}, \quad \tilde{y} = \frac{1901}{900}.$$

$$\|\bar{x} - \tilde{\tilde{x}}\| = 1.57 = e_A(\bar{x}) = e_R(\bar{x}) \quad \text{elevatissimo!}$$

Nota di trascrizione (pagina 27): uguaglianza degli errori riportata come nel manoscritto; norma non specificata.

$$\tilde{\tilde{A}}\tilde{\tilde{x}} = \tilde{\tilde{b}} \implies (A + \delta A)(\bar{x} + \delta \bar{x}) = b + \delta b.$$

$$\frac{\|\delta \bar{x}\|}{\|\bar{x}\|} \leq \underbrace{\|A\| \|A^{-1}\|}_K \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right).$$

K è detto indice di condizionamento del sistema.

4 Interpolazione

È un metodo che consiste nell'approssimazione di una funzione dove conosciamo solo alcuni punti. L'insieme dei punti x_i noti sono chiamati nodi. Certe volte è possibile interpolare una funzione anche se quest'ultima è nota ma è troppo complessa.

$$f(x) \simeq g(x; a_0, a_1, \dots, a_n), \quad f(x_i) = g(x_i) \quad \forall i = 0, \dots, n.$$

Il procedimento più usato è quello nel quale

$$g(x; a_0, \dots, a_n) = \sum_{i=0}^n a_i \phi_i(x), \quad f(x_j) = \sum_{i=0}^n a_i \phi_i(x_j).$$

g deve passare dai nodi. Risolvere quest'ultima equazione, trovando i coefficienti a_i , è il metodo dei coefficienti indeterminati.

Interpolazione polinomiale

Con $\phi_i(x) = x^i$ per ogni i ,

$$g(x; a_0, \dots, a_n) = \sum_{i=0}^n a_i x^i,$$

è un polinomio. Le condizioni sono

$$a_0 + a_1 x_j + a_2 x_j^2 + \dots + a_n x_j^n = f(x_j), \quad j = 0, \dots, n.$$

Sono riassumibili come $V\bar{a} = \bar{y}$, con

$$\bar{y} = (f(x_0), \dots, f(x_n))^T, \quad \bar{a} = (a_0, \dots, a_n)^T, \quad V = \begin{pmatrix} 1 & x_0 & x_0^2 & \dots & x_0^n \\ 1 & x_1 & x_1^2 & \dots & x_1^n \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^n \end{pmatrix} \in \mathbb{R}^{(n+1) \times (n+1)}.$$

Se V (matrice di Vandermonde) è non singolare il problema dell'interpolazione ammette un'unica soluzione. V non è singolare se i nodi sono distinti a due a due. Risolvere il metodo dei coefficienti indeterminati richiede la soluzione di un sistema che potrebbe essere enorme e anche mal condizionato.

Polinomio interpolante di Lagrange

$$L_n(x) = \sum_{k=0}^n \ell_{nk}(x) f(x_k),$$

con $\ell_{nk}(x)$ polinomio di grado n . Ponendo le condizioni $L_n(x_i) = f(x_i)$:

$$L_n(x_i) = \sum_{k=0}^n \ell_{nk}(x_i) f(x_k) = f(x_i) \implies \ell_{nk}(x_i) = \begin{cases} 0 & k \neq i \\ 1 & k = i. \end{cases}$$

Per far sì che il polinomio si annulli per x_i con $i \neq k$, poniamo

$$\ell_{nk}(x) = c_k \prod_{\substack{i=0 \\ i \neq k}}^n (x - x_i), \quad \ell_{nk}(x_k) = c_k \prod_{\substack{i=0 \\ i \neq k}}^n (x_k - x_i) = 1.$$

Quindi

$$c_k = \frac{1}{\prod_{i \neq k} (x_k - x_i)}, \quad L_n(x) = \sum_{k=0}^n \left(\prod_{\substack{i=0 \\ i \neq k}}^n \frac{x - x_i}{x_k - x_i} \right) f(x_k).$$

$\ell_{nk}(x)$ sono i polinomi fondamentali di Lagrange.

Errori di interpolazione

$$e(x) = f(x) - P_n(x).$$

$f(x)$ non è nota, quindi l'errore (o resto) dell'interpolazione non è direttamente calcolabile.

Teorema di rappresentazione dell'errore di interpolazione

Sia $f \in C^{n+1}([a, b])$ e $x_i \in [a, b]$. Se $P_n(x)$ è il polinomio di interpolazione di $f(x)$ sui punti x_i , per ogni $x \in [a, b]$ esiste $\xi = \xi(x)$ tale che

$$e(x) = f(x) - P_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} (x - x_0) \cdots (x - x_n) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x),$$

con $\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i)$ polinomio nodale. **Esempio.**

$$e(x) = f(x) - L_1(x) = \frac{f''(\xi_x)}{2!} (x - x_0)(x - x_1).$$

Ponendo $x = x_0 + hs$, con $h = x_1 - x_0$, $s \in [0, 1]$, diventa

$$\begin{aligned} e(x) &= \frac{f''(\xi_x)}{2} hs(x_0 + hs - x_1) \\ &= \frac{f''(\xi_x)}{2} hs(hs - h) = \frac{f''(\xi_x)}{2} h^2 s(s - 1) \\ &= \frac{f''(x_0 + \bar{s}h)}{2} h^2 s(s - 1). \end{aligned}$$

$$\max_{s \in [0, 1]} |s(s - 1)| = \frac{1}{4} \implies |e(x)| \leq \frac{h^2}{8} \max_{x \in [x_0, x_1]} |f''(x)|.$$


Fenomeno di Runge

$$f(x) = \frac{1}{1+x^2}, \quad x \in [-5, 5], \quad x_i = -5 + \frac{10i}{n}.$$

$L_n(x)$ si allontana sempre più da $f(x)$ con $n \rightarrow +\infty$. Più suddivido l'intervallo $[a, b]$, più aumenta l'oscillazione e l'ampiezza.

$$\lim_{n \rightarrow \infty} \max_{x \in [-5, 5]} |f(x) - L_n(x)| = +\infty.$$

Questo fenomeno è chiamato fenomeno di Runge ed è un grave problema dell'interpolazione di Lagrange.



Minimizzare il resto nel problema di interpolazione

$$e(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \omega_{n+1}(x).$$

Non possiamo modificare il fattore $f^{(n+1)}(\xi_x)/(n+1)!$, ma possiamo rendere $\omega_{n+1}(x)$ un polinomio di grado al più $n+1$ tale che

$$\max_{x \in [a, b]} |\tilde{p}(x)| = \min_{p \in \mathcal{P}_{n+1}} \max_{x \in [a, b]} |p(x)|.$$

È fattibile utilizzando i polinomi di Chebyshev. *Nota (pagina 31): nel problema di minimo la famiglia deve intendersi monica, come il polinomio nodale; nel manoscritto questa restrizione non è esplicitata.*

Polinomio di Chebyshev

$$T_n(x) = \cos(n \arccos x), \quad x \in [-1, 1].$$

Esempio: $T_0(x) = \cos 0 = 1$, $T_1(x) = x$.

Vale la seguente formula ricorsiva:

$$\boxed{T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x)}.$$

Dimostrazione. Posto $\arccos x = \theta$, $\cos \theta = x$:

$$T_n(x) = \cos(n\theta),$$

$$T_{n+1}(x) = \cos[(n+1)\theta] = \cos(n\theta)\cos\theta - \sin(n\theta)\sin\theta,$$

$$T_{n-1}(x) = \cos[(n-1)\theta] = \cos(n\theta)\cos\theta + \sin(n\theta)\sin\theta.$$

$$T_{n+1}(x) = 2\cos(n\theta)\cos\theta - T_{n-1}(x) = 2xT_n(x) - T_{n-1}(x).$$

$$T_0 = 1, \quad T_1 = x, \quad T_2 = 2x \cdot x - 1 = 2x^2 - 1, \quad T_3 = 2x(2x^2 - 1) - x = 4x^3 - 3x.$$

Quindi $T_n(x) = 2^{n-1}x^n + \dots$.

Proprietà di T_n

1. $\max_{x \in [-1,1]} |T_n(x)| = 1$.
2. $T_{2k}(-x) = T_{2k}(x)$ e $T_{2k+1}(-x) = -T_{2k+1}(x)$.
3. $|T_n(x)| = 1$ per $x = \cos(k\pi/n)$. In particolare $T_n(x_k) = (-1)^k$, $k = 0, \dots, n$.
4. $T_n(x_k) = 0$ per $x_k = \cos((2k+1)\pi/(2n))$, $k = 0, \dots, n-1$.

Teorema di minimax

Sia $p_n(x)$ un qualsiasi polinomio monico di grado n .

$$\frac{1}{2^{n-1}} = \max_{x \in [-1, 1]} |\widehat{T}_n(x)| \leq \max_{x \in [-1, 1]} |p_n(x)|, \quad \widehat{T}_n(x) = \frac{1}{2^{n-1}} T_n(x).$$

$\widehat{T}_n$ è il polinomio di Chebyshev monico. In realtà il massimo di $|p_n|$ è maggiore di quello di $|\widehat{T}_n|$ (salvo coincidenza): il polinomio di Chebyshev monico è il polinomio di grado n con il più piccolo dei massimi. Ponendo $\omega_{n+1}(x) = \widehat{T}_{n+1}(x)$ avremo

$$|e(x)| = \left| \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \widehat{T}_{n+1}(x) \right| \leq \frac{1}{(n+1)! 2^n} \max_{x \in [-1, 1]} |f^{(n+1)}(x)|.$$

Se $[a, b] \neq [-1, 1]$ bisogna effettuare una trasformazione lineare tra i due intervalli:

$$t = \frac{b-a}{2}x + \frac{a+b}{2}, \quad x \in [-1, 1].$$

Detti x_k gli zeri di $T_{n+1}(x)$,

$$\tau_k = \frac{b-a}{2}x_k + \frac{b+a}{2}, \quad k = 0, \dots, n, \quad x_k = \cos \frac{(2k+1)\pi}{2(n+1)}.$$

Usando gli zeri del polinomio di Chebyshev come nodi avremo il resto minimo (errore massimo). I nodi da usare sono dunque τ_k , trasformati degli zeri di $\widehat{T}_{n+1}$.

Se il numero di nodi è sufficientemente elevato la funzione interpolante potrebbe mostrare un comportamento fortemente oscillatorio. A questo punto è preferibile usare l'approccio spline.

Funzioni spline

$$\Delta: \quad a \equiv x_0 < x_1 < x_2 < \cdots < x_n < x_{n+1} \equiv b$$

è una decomposizione dell'intervallo $[a, b]$. $s(x)$ è una funzione spline di grado $m \geq 1$ relativa alla decomposizione Δ che ha le seguenti proprietà:

1. $s|_{[x_i, x_{i+1}]} \in \mathcal{P}_m$.
2. $s^{(k)}(x)$ è continua in $[a, b]$ per ogni $k \in [0, m-1]$, cioè $s \in C^{m-1}$.

Approssimazione ai minimi quadrati

$$\varepsilon_i = \phi(a_0, a_1, \dots, a_m, x_i) - y_i, \quad i = 0, 1, \dots, n,$$

è la differenza tra il valore assunto dalla funzione interpolante e la funzione effettiva nei nodi $y_i = f(x_i)$. Ricerchiamo $\bar{a} = (a_0, \dots, a_m)$ tale che $\bar{\varepsilon} = (\varepsilon_0, \dots, \varepsilon_n)$ abbia la minima norma euclidea al quadrato:

$$\|\bar{\varepsilon}\|_2^2 = \sum_{i=0}^n \varepsilon_i^2 = \sum_{i=0}^n (\phi(a_0, \dots, a_m, x_i) - y_i)^2.$$

$$Q(a_0^*, \dots, a_m^*) = \min_{a_0, \dots, a_m \in \mathbb{R}} Q(a_0, \dots, a_m), \quad Q = \|\bar{\varepsilon}\|_2^2.$$

Analizziamo il caso della retta $\phi(a_0, a_1, x) = \alpha x + \beta$.

Retta di regressione

$$\phi(\alpha, \beta, x) = \alpha x + \beta, \quad \alpha, \beta \in \mathbb{R}, \quad \phi(\alpha, \beta, x_i) - y_i = \alpha x_i + \beta - y_i.$$

$$\Psi(\alpha, \beta) = \sum_{i=0}^n (\alpha x_i + \beta - y_i)^2 \quad \text{da minimizzare.}$$

$$\frac{\partial \Psi}{\partial \alpha} = \sum_{i=0}^n 2x_i(\alpha x_i + \beta - y_i) = 0, \quad \frac{\partial \Psi}{\partial \beta} = \sum_{i=0}^n 2(\alpha x_i + \beta - y_i) = 0.$$

$$\begin{cases} \alpha \sum x_i^2 + \beta \sum x_i - \sum x_i y_i = 0, \\ \alpha \sum x_i + \beta \sum 1 - \sum y_i = 0 \end{cases} \implies \begin{cases} \alpha \sum x_i^2 + \beta \sum x_i = \sum x_i y_i, \\ \alpha \sum x_i + \beta(n+1) = \sum y_i. \end{cases}$$

Posti $S_{xx} = \sum x_i^2$, $S_x = \sum x_i$, $S_y = \sum y_i$, $S_{xy} = \sum x_i y_i$:

$$\begin{cases} S_{xx}\alpha + S_x\beta = S_{xy}, \\ S_x\alpha + (n+1)\beta = S_y. \end{cases}$$

Usando Cramer:

$$\alpha = \frac{\begin{vmatrix} S_{xy} & S_x \\ S_y & n+1 \end{vmatrix}}{\begin{vmatrix} S_{xx} & S_x \\ S_x & n+1 \end{vmatrix}} = \frac{(n+1)S_{xy} - S_x S_y}{S_{xx}(n+1) - S_x^2},$$
$$\beta = \frac{\begin{vmatrix} S_{xx} & S_{xy} \\ S_x & S_y \end{vmatrix}}{\begin{vmatrix} S_{xx} & S_x \\ S_x & n+1 \end{vmatrix}} = \frac{S_{xx}S_y - S_x S_{xy}}{S_{xx}(n+1) - S_x^2}.$$

Quadratura

La quadratura è una tecnica che consente di calcolare

$$\int_a^b f(x) dx = I(f)$$

conoscendo $f(x)$ nell'intervallo $[a, b]$, quando diventa difficile o costoso calcolare $F(x)$ o quando si conoscono solo un certo numero di punti appartenenti ad $f(x)$.

Formule di quadratura di tipo interpolatorio

$$\sum_{k=0}^m w_k f(x_k) \simeq I(f).$$

Formule di quadratura con x_k nodi e w_k pesi. Poniamo $f(x) = L_m(x) + e(x)$:

$$\begin{aligned} \int_a^b f(x) dx &= \int_a^b L_m(x) dx + \int_a^b e(x) dx \\ &= \int_a^b \sum_{k=0}^m \ell_{mk}(x) f(x_k) dx + \int_a^b e(x) dx \\ &= \sum_{k=0}^m \left[\int_a^b \ell_{mk}(x) dx \right] f(x_k) + \int_a^b e(x) dx. \end{aligned}$$

Pongo

$$w_k = \int_a^b \ell_{mk}(x) dx, \quad R_{m+1}(f) = \int_a^b e(x) dx.$$

Le ℓ_{mk} sono le formule interpolatrici; $R_{m+1}(f)$ è il resto della formula di quadratura:

$$\boxed{I(f) = \sum_{k=0}^m w_k f(x_k) + R_{m+1}(f)}, \quad I(f) \simeq \sum_{k=0}^m w_k f(x_k).$$

Grado di precisione

Una formula ha grado di precisione q se fornisce il valore esatto di $I(f)$ quando f è un polinomio di grado al più q e $\exists p(x) \in \mathcal{P}_{q+1} \setminus \mathcal{P}_q$ tale che $R_{q+1}(f) \neq 0$.

Osservazione. Ogni formula di quadratura di tipo interpolatorio ha grado di precisione $q \geq m$ ($m = \text{numero dei nodi} - 1$). **Dimostrazione.**

$$\int_a^b p_m(x) dx = \sum_{i=0}^m w_i p_m(x_i) + R_{m+1}(f),$$

$$R_{m+1}(f) = \int_a^b e(x) dx = \int_a^b \omega_{m+1}(x) \frac{p_m^{(m+1)}(x)}{(m+1)!} dx \equiv 0,$$

poiché $p_m^{(m+1)}(x) = 0$ per ogni $p_m \in \mathcal{P}_m$.

Formule di Newton–Cotes

Suddivido $[a, b]$ in m sottointervalli di ampiezza h , con

$$h = \frac{b-a}{m}, \quad x_i = a + ih, \quad i = 0, 1, \dots, m.$$

$$\int_a^b f(x) dx = \sum_{i=0}^m w_i f(x_i) + R_{m+1}(f)$$

è la formula di Newton–Cotes. **Proprietà:** $w_i = w_{m-i}$ (proprietà di simmetria). **Dimostrazione.**

$$c = \frac{x_i + x_{m-i}}{2} = \frac{b+a}{2} \implies \begin{cases} x_i = 2c - x_{m-i}, \\ x_{m-i} = 2c - x_i. \end{cases}$$

$$\begin{aligned} w_k &= \int_a^b \prod_{\substack{i=0 \\ i \neq k}}^m \frac{x - x_i}{x_k - x_i} dx \\ &= \int_a^b \prod_{\substack{i=0 \\ i \neq k}}^m \frac{x - 2c + x_{m-i}}{2c - x_{m-k} - 2c + x_{m-i}} dx \\ &= \int_a^b \prod_{\substack{i=0 \\ i \neq k}}^m \frac{2c - x - x_{m-i}}{x_{m-k} - x_{m-i}} dx. \end{aligned}$$

Posto $t = 2c - x$, si ha $t = 2c - a = b$, $t = 2c - b = a$, $dt = -dx$: si scambiano gli estremi di integrazione,


$$\int_a^b f(x) dx = - \int_b^a f(t) dt = \int_a^b f(t) dt.$$

Quindi

$$w_k = \int_a^b \prod_{\substack{i=0 \\ i \neq k}}^m \frac{t - x_{m-i}}{x_{m-k} - x_{m-i}} dt = \int_a^b \prod_{\substack{j=0 \\ j \neq m-k}}^m \frac{t - x_j}{x_{m-k} - x_j} dt = w_{m-k}, \quad j = m - i.$$

Formula dei trapezi

$$x_0 = a, \quad x_1 = b, \quad h = b - a, \quad T_2 = w_0 f(x_0) + w_1 f(x_1).$$



$$\begin{aligned} w_0 &= \int_a^b \ell_{10}(x) dx = \int_a^b \frac{x - x_1}{x_0 - x_1} dx = \int_a^b \frac{x - b}{a - b} dx \\ &= \frac{1}{a - b} \left[\frac{(x - b)^2}{2} \right]_{x=a}^{x=b} = -\frac{h^2}{2} \frac{1}{-h} = \frac{h}{2}. \end{aligned}$$

a e b sono nodi simmetrici rispetto a c , quindi $w_0 = w_1 = h/2$:

$$\boxed{T_2 = \frac{h}{2}(f(a) + f(b))} \quad \text{formula dei trapezi.}$$

Resto nella formula dei trapezi

$$R_2(f) = \frac{1}{2!} \int_a^b (x - a)(x - b) f''(\xi_x) dx.$$

Per manipolare quest'espressione abbiamo bisogno di conoscere il teorema della media generalizzato.

Teorema della media generalizzato

Siano $f, g : [a, b] \rightarrow \mathbb{R}$, f continua, $g(x)$ a segno costante e $g(x) \neq 0$ per ogni $x \in (a, b)$. Allora

$$\int_a^b f(x)g(x) dx = f(\bar{x}) \int_a^b g(x) dx, \quad \bar{x} \in [a, b].$$

Poiché $(x - a)(x - b)$ è a segno costante,

$$\int_a^b (x - a)(x - b) f''(\xi_x) dx = f''(\eta) \int_a^b (x - a)(x - b) dx$$

e quindi

$$R_2(f) = \frac{f''(\eta)}{2!} \int_a^b (x - a)(x - b) dx.$$

Posto $h = b - a$ e $x = a + ht$, con $t \in [0, 1]$, $dx = h dt$:

$$\begin{aligned} R_2(f) &= \frac{f''(\eta)}{2!} \int_0^1 ht(-h + ht)h dt \\ &= \frac{f''(\eta)}{2!} \int_0^1 h^3 t(t-1) dt = \frac{f''(\eta)}{2!} h^3 \left[\frac{t^3}{3} - \frac{t^2}{2} \right]_0^1 = -\frac{h^3}{12} f''(\eta). \end{aligned}$$

$R_2(f) = 0 \iff f \in \mathcal{P}_1$. Il grado di precisione è $q = 1$ (con f di grado 2, $R_2(f) \neq 0$).

Formula di Simpson

$$x_0 = a, \quad x_2 = b, \quad x_1 = c = \frac{b+a}{2}, \quad h = \frac{b-a}{2},$$

$$S_3 = w_0 f(a) + w_1 f(c) + w_2 f(b).$$

$$w_0 = \int_a^b \ell_{20}(x) dx = \int_a^b \frac{(x-b)(x-c)}{(a-b)(a-c)} dx.$$

Posto $x = c + ht$, $dx = h dt$:

$$\begin{aligned} w_0 &= \int_{-1}^1 \frac{(ht-h)(ht)}{(-2h)(-h)} h dt = \int_{-1}^1 \frac{(t-1)ht}{2} dt \\ &= \frac{h}{2} \left[\frac{t^3}{3} - \frac{t^2}{2} \right]_{-1}^1 = \frac{h}{2} \left(-\frac{1}{6} + \frac{5}{6} \right) = \frac{2}{3} \frac{h}{2} = \frac{h}{3}. \end{aligned}$$

$w_0 = w_2 = h/3$ per simmetria.

$$\begin{aligned} w_1 &= \int_a^b \ell_{21}(x) dx = \int_a^b \frac{(x-a)(x-b)}{(c-a)(c-b)} dx \\ &= \int_{-1}^1 \frac{h(1+t)(ht-h)}{h(-h)} h dt = h \int_{-1}^1 (1-t^2) dt \\ &= h \left[t - \frac{t^3}{3} \right]_{-1}^1 = h \left(\frac{2}{3} + \frac{2}{3} \right) = \frac{4}{3} h. \end{aligned}$$

$$\boxed{S_3 = \frac{h}{3}(f(a) + 4f(c) + f(b))} \quad \text{formula di Simpson.}$$

$$\boxed{R_3(f) = -h^5 \frac{f^{(4)}(\sigma)}{90}}, \quad \sigma \in (a, b), \quad h = \frac{b-a}{2}.$$

Grado di precisione $q = 3$.

Formula del punto di mezzo

Sia $c = (a+b)/2$. Sviluppo la serie di Taylor con c punto iniziale:

$$f(x) = f(c) + f'(c)(x-c) + \frac{f''(\xi_x)}{2!}(x-c)^2, \quad \xi_x \in [a, b].$$

$$\begin{aligned} \int_a^b f(x) dx &= \int_a^b f(c) dx + f'(c) \underbrace{\int_a^b (x-c) dx}_0 + \int_a^b \frac{f''(\xi)}{2} (x-c)^2 dx \\ &= f(c)(b-a) + \int_a^b \frac{f''(\xi)}{2} (x-c)^2 dx. \end{aligned}$$

Posto $h = b-a$, $\int_a^b f(x) dx \simeq hf(c)$.

$$\begin{aligned} R(f) &= \int_a^b \frac{f''(\xi)}{2} (x-c)^2 dx = \frac{f''(\eta)}{2} \int_a^b (x-c)^2 dx \\ &= \frac{f''(\eta)}{2} \left. \frac{(x-c)^3}{3} \right|_a^b = \frac{f''(\eta)}{2} \left(\frac{h^3}{24} + \frac{h^3}{24} \right) = \frac{h^3}{24} f''(\eta). \end{aligned}$$

$$\boxed{R(f) = \frac{h^3}{24} f''(\eta)}, \quad \boxed{M = hf(c)}.$$

Grado di precisione $q = 1$. Il grado di precisione di questa tecnica è uguale a quello del trapezio, ma questa formula necessita solo di un punto.

Formule di quadratura composte

Consiste nel dividere l'intervallo $[a, b]$ in N sottointervalli con ampiezza uguale, aumentando la precisione.

$$\int_a^b f(x) dx = \sum_{i=0}^{N-1} \int_{x_i}^{x_{i+1}} f(x) dx, \quad x_i = a + ih, \quad h = \frac{b-a}{N}.$$

Formula dei trapezi composti

$$\begin{aligned} \int_a^b f(x) dx &= \sum_{i=0}^{N-1} \left[\frac{h}{2} (f(x_i) + f(x_{i+1})) - \frac{1}{12} h^3 f''(\eta_i) \right] \\ &= \frac{h}{2} \sum_{i=0}^{N-1} (f(x_i) + f(x_{i+1})) - \frac{1}{12} h^3 \sum_{i=0}^{N-1} f''(\eta_i) \\ &= \frac{h}{2} (f(x_0) + f(x_N)) + h \sum_{i=1}^{N-1} f(x_i) - \frac{h^3}{12} N f''(\eta), \end{aligned}$$

con $\eta_i \in (x_i, x_{i+1})$ e $\eta \in (a, b)$.

$$T_c^{(h)} = \frac{h}{2} (f(x_0) + f(x_N)) + h \sum_{i=1}^{N-1} f(x_i).$$

$$R_T = -\frac{h^3}{12} N f''(\eta) = -\frac{(b-a)^3}{12N^3} N f''(\eta) = \boxed{-\frac{(b-a)^3}{12N^2} f''(\eta)}.$$

Teorema della media nel discreto:

$$\sum_{i=1}^N f(x_i) = N f(\bar{x}), \quad x_i \in [a, b], \quad \bar{x} \in (a, b).$$

Sappiamo che

$$\begin{aligned} |R_T| &\leq \frac{1}{12} \frac{(b-a)^3}{N^2} \underbrace{\max_{x \in (a,b)} |f''(x)|}_M \\ \varepsilon &\geq \frac{1}{12} \frac{(b-a)^3}{N_\varepsilon^2} M \implies N_\varepsilon \geq \sqrt{\frac{(b-a)^3 M}{12\varepsilon}}. \end{aligned}$$

Possiamo stabilire in quanti pezzi suddividere $[a, b]$ per ottenere una precisione $\varepsilon \geq |R_T|$.

Formula di Simpson composta

Suddivido $[a, b]$ in N intervalli, con N pari:

$$\begin{aligned} \int_a^b f(x) dx &= \sum_{i=0}^{N/2-1} \int_{x_{2i}}^{x_{2i+2}} f(x) dx \\ &= \sum_{i=0}^{N/2-1} \left[\frac{h}{3} (f(x_{2i}) + 4f(x_{2i+1}) + f(x_{2i+2})) - \frac{h^5}{90} f^{(4)}(\eta_i) \right]. \end{aligned}$$

$$\int_a^b f(x) dx = \frac{h}{3} \sum_{i=0}^{N/2-1} [f(x_{2i}) + 4f(x_{2i+1}) + f(x_{2i+2})] - \frac{h^5 N}{180} f^{(4)}(\eta).$$

$$S_c(h) = \frac{h}{3} \left[f(x_0) + f(x_N) + 2 \sum_{i=1}^{N/2-1} f(x_{2i}) + 4 \sum_{i=0}^{N/2-1} f(x_{2i+1}) \right].$$

$$R_S = -\frac{h^5 N}{90} f^{(4)}(\eta) = -\frac{(b-a)^5}{180N^4} f^{(4)}(\eta).$$

Nota di trascrizione (pagina 42): il denominatore 90 nella prima espressione di R_S compare così nell'originale, mentre le espressioni adiacenti hanno 180.

$$|R_S| \leq \frac{(b-a)^5}{180N^4} \max_{x \in (a,b)} |f^{(4)}(x)|,$$

$$\varepsilon \geq \frac{(b-a)^5}{180N_\varepsilon^4} M \implies N_\varepsilon \geq \sqrt[4]{\frac{(b-a)^5 M}{180\varepsilon}}.$$

Formula del punto di mezzo composta

$$\begin{aligned} \int_a^b f(x) dx &= \sum_{i=0}^{N/2-1} \int_{x_{2i}}^{x_{2i+2}} f(x) dx \\ &= \sum_{i=0}^{N/2+1} 2hf(x_{2i+1}) + \sum_{i=0}^{N/2-1} \frac{(2h)^3}{24} f''(\eta_i) \\ &= 2h \sum_{i=0}^{N/2+1} f(x_{2i+1}) + \frac{h^3}{6} N f''(\eta). \end{aligned}$$

$$M_c(h) = 2h \sum_{i=0}^{N/2-1} f(x_{2i+1}), \quad R_M = \frac{(b-a)^3}{6N^2} f''(\eta), \quad N_\varepsilon \geq \sqrt{\frac{(b-a)^3 M}{6\varepsilon}}.$$

Nota di trascrizione (pagina 42): gli indici $N/2 + 1$ delle due somme intermedie e il coefficiente del resto sono riprodotti come nella fonte; la formula evidenziata ha indice $N/2 - 1$.

Derivazione numerica

È una tecnica per trovare le derivate di una funzione senza calcolare effettivamente $f^{(m)}(t)$. Supponiamo che $f \in C^k([a, b])$ con k sufficientemente grande per i nostri scopi e dividiamo $[a, b]$ in

$$a \equiv t_0 < t_1 < t_2 < \dots < t_{N-1} < t_N \equiv b.$$

Considero tre punti consecutivi t_{m-1}, t_m, t_{m+1} :

$$t_{m-1} = t_m - h, \quad t_{m+1} = t_m + h.$$

$$f(t_{m+1}) = f(t_m) + f'(t_m)h + \frac{f''(t_m)}{2}h^2 + \frac{f^{(3)}(t_m)}{6}h^3 + \frac{f^{(4)}(\xi)}{24}h^4,$$

$$f(t_{m-1}) = f(t_m) - f'(t_m)h + \frac{f''(t_m)}{2}h^2 - \frac{f^{(3)}(t_m)}{6}h^3 + \frac{f^{(4)}(\eta)}{24}h^4.$$

$$f(t_{m+1}) + f(t_{m-1}) = 2f(t_m) + f''(t_m)h^2 + \frac{h^4}{24}(f^{(4)}(\xi) + f^{(4)}(\eta)).$$

$$f(t_{m+1}) + f(t_{m-1}) \simeq 2f(t_m) + f''(t_m)h^2$$

$$f''(t_m) \simeq \frac{f(t_{m+1}) + f(t_{m-1}) - 2f(t_m)}{h^2}.$$

$$E(f''(t_m)) = -\frac{h^2}{24}(f^{(4)}(\xi) + f^{(4)}(\eta)) = -\frac{h^2}{12}f^{(4)}(\chi), \quad \chi \in [t_{m-1}, t_{m+1}].$$

Provo ad approssimare la derivata prima:

$$f(t_{m+1}) = f(t_m) + f'(t_m)h + \frac{f''(t_m)}{2}h^2 + \frac{f^{(3)}(\sigma_1)}{6}h^3,$$

$$f(t_{m-1}) = f(t_m) - f'(t_m)h + \frac{f''(t_m)}{2}h^2 - \frac{f^{(3)}(\sigma_2)}{6}h^3.$$

$$f(t_{m+1}) - f(t_{m-1}) = 2f'(t_m)h + \frac{f^{(3)}(\sigma)}{3}h^3.$$

$$f'(t_m) \simeq \frac{f(t_{m+1}) - f(t_{m-1})}{2h}$$

formula delle differenze centrali.

$$E(f'(t_m)) = -\frac{f^{(3)}(\delta)}{6}h^2, \quad \delta \in [t_{m-1}, t_{m+1}].$$

Differenze in avanti

Sviluppo con Taylor $f(t_{m+1})$:

$$f(t_{m+1}) = f(t_m) + hf'(t_m) + h^2 \frac{f''(\sigma)}{2}$$

$$\boxed{f'(t_m) \simeq \frac{f(t_{m+1}) - f(t_m)}{h}}, \quad \boxed{E(f'(t_m)) = -\frac{h}{2}f''(\sigma)}, \quad \sigma \in [t_m, t_{m+1}].$$

Differenze all'indietro

Sviluppo con Taylor $f(t_{m-1})$:

$$f(t_{m-1}) = f(t_m) - hf'(t_m) + h^2 \frac{f''(\sigma)}{2}$$

$$\boxed{f'(t_m) \simeq \frac{f(t_m) - f(t_{m-1})}{h}}, \quad \boxed{E(f'(t_m)) = \frac{h}{2}f''(\sigma)}, \quad \sigma \in [t_{m-1}, t_m].$$

Nota. Queste formule hanno ordine 1 ($E \propto h$), mentre la formula delle differenze centrali ha ordine 2 ($E \propto h^2$), quindi è più accurata.

Equazioni differenziali

Definiamo un problema di Cauchy ai valori iniziali:

$$\begin{cases} y'(t) = f(t, y(t)), \\ y(t_0) = y_0, \end{cases}$$

dove $f : [t_0, T] \times \mathbb{R} \rightarrow \mathbb{R}$, con $f \in C([t_0, T])$ e lipschitziana. **Lipschitzianità.** f è lipschitziana rispetto a y se

$$\exists L > 0 : \quad \forall x, y \in \mathbb{R} : \quad |f(t, x) - f(t, y)| \leq L|x - y|, \quad \forall t \in [t_0, T].$$

$y(t)$ è soluzione dell'equazione differenziale se rispetta le condizioni del sistema ed è $y \in C^1([t_0, T])$.
Si discretizza l'intervallo di integrazione $[t_0, T]$:

$$t_{m+1} = t_m + h, \quad t_m = t_0 + mh, \quad m = 0, 1, \dots, N, \quad h = \frac{T - t_0}{N}.$$

$$\begin{aligned} y'(t) &= f(t, y(t)) \\ \implies \int_{t_m}^{t_{m+1}} y'(t) dt &= \int_{t_m}^{t_{m+1}} f(t, y(t)) dt \\ \implies y(t_{m+1}) - y(t_m) &= \int_{t_m}^{t_{m+1}} f(t, y(t)) dt. \end{aligned}$$

Metodo di Euler esplicito

$$\begin{aligned} y(t_{m+1}) - y(t_m) &= hf(t_m, y(t_m)) + \text{errore} \\ y(t_{m+1}) - y(t_m) &\simeq hf(t_m, y(t_m)). \end{aligned}$$

Approssimo $y_{m+1} \simeq y(t_{m+1})$, $y_m \simeq y(t_m)$:

$$y_{m+1} - y_m = hf(t_m, y_m) \iff \boxed{y_{m+1} = y_m + hf(t_m, y_m)}.$$

È chiamato metodo di Euler esplicito in quanto, noto y_m , è possibile calcolare esplicitamente y_{m+1} .

Metodo di Euler implicito

$$\begin{aligned} y(t_{m+1}) - y(t_m) &= hf(t_{m+1}, y(t_{m+1})) + \text{errore} \\ y(t_{m+1}) - y(t_m) &\simeq hf(t_{m+1}, y(t_{m+1})) \\ y_{m+1} - y_m &\simeq hf(t_{m+1}, y_{m+1}) \iff \boxed{y_{m+1} = y_m + hf(t_{m+1}, y_{m+1})}. \end{aligned}$$


Metodo dei trapezi

$$y(t_{m+1}) - y(t_m) \simeq \frac{h}{2}[f(t_m, y(t_m)) + f(t_{m+1}, y(t_{m+1}))].$$

$$y_{m+1} = y_m + \frac{h}{2}[f(t_m, y_m) + f(t_{m+1}, y_{m+1})].$$

Metodo del midpoint

$$y(t_{m+2}) - y(t_m) \simeq 2hf(t_{m+1}, y(t_{m+1})), \quad y_{m+2} = y_m + 2hf(t_{m+1}, y_{m+1}).$$



Classificazione dei metodi numerici

Se la soluzione nell'istante t_{m+k} dipende da k valori ottenuti in precedenza $t_{m+k-1}, \dots, t_{m+1}, t_m$, il metodo si dice a k passi (k -steps). Euler e trapezi sono a un passo (one-step); midpoint è a due passi.

$$y_{m+k} = y_m + h\Phi(t_m, \dots, t_{m+k}, y_m, \dots, y_{m+k}),$$

$$y_{m+1} = y_m + h\Phi(t_m, t_{m+1}, y_m, y_{m+1}).$$

Se $y_{m+1} = y_m + h\Phi(t_m, t_{m+1}, y_m)$, o più in generale

$$y_{m+k} = y_m + h\Phi(t_m, \dots, t_{m+k}, y_m, \dots, y_{m+k-1}),$$

il metodo è esplicito (Euler esplicito e midpoint).

Se ciò non fosse, il metodo è implicito (Euler implicito e trapezi). Per calcolare y_{m+k} in un metodo implicito dovremo risolvere un'equazione che potrebbe non essere lineare se $f(t, y)$ non è lineare.

$$y_{m+1} = y_m + hf(t_{m+1}, y_{m+1}), \quad g(x) = y_m + hf(t_{m+1}, x).$$


$$\boxed{y_{m+1}^{(r+1)} = g(y_{m+1}^{(r)}) = y_m + hf(t_{m+1}, y_{m+1}^{(r)})}, \quad y_{m+1}^{(0)} = y_m.$$

Affinché il metodo converga $|g'(x)| < 1$:

$$g'(x) = h \frac{\partial f}{\partial y}(t_{m+1}, x), \quad \left| h \frac{\partial f}{\partial y}(t_{m+1}, x) \right| < 1 \implies h \left| \frac{\partial f}{\partial y} \right| < 1 \implies \left| \frac{\partial f}{\partial y} \right| < \frac{1}{h}.$$

Questa condizione è verificata sicuramente perché $f(t, y)$ è lipschitziana, quindi $hL < 1$. *Nota (pagina 47): la frase è riportata fedelmente; richiede che il passo sia scelto sufficientemente piccolo.* Nel metodo di Euler esplicito

$$y = y_0 + f(t_0, y_0)(t - t_0), \quad t = t_0 + h \implies y = y_0 + hf(t_0, y_0) \implies y_{k+1} = y_k + hf(t_k, y_k).$$



Un altro metodo che coincide con il metodo di Euler esplicito consiste nel dividere in N intervalli

$$t_0 < t_1 < t_2 < \dots < t_N \equiv T, \quad y'(t_m) = f(t_m, y_m) \simeq \frac{y_{m+1} - y_m}{h} \quad (\text{differenze in avanti}).$$

Minore è h , più precisa sarà la soluzione. Il metodo è convergente se migliora l'approssimazione diminuendo opportunamente il passo h .

Studio della convergenza

$$e(t_m, h) := y(t_m) - y_m$$

è l'errore globale. La convergenza consiste nell'annullarsi di $e(t_m, h)$ quando $h \rightarrow 0$. Uno schema è convergente nel punto T quando

$$\lim_{h \rightarrow 0} e(t_m, h) = 0 \quad \Longleftrightarrow \quad \lim_{m \rightarrow +\infty} y_m = y(T).$$

Supponiamo di aver applicato Euler esplicito e indico con y_m la soluzione approssimata. Chiamo $z(t)$ la soluzione dell'equazione differenziale che si ottiene prendendo y_m come dato iniziale. Nella soluzione globale ci sono due errori:

1. Errore di troncamento locale:

$$I_m(h, f) := z(t_{m+1}) - [\underbrace{y_m}_{z(t_m)} + hf(t_m, y_m)].$$

Quest'errore è dovuto alla sostituzione della soluzione con la tangente.

$$\tau_m(h, f) = \frac{I_m(h, f)}{h} = \frac{z(t_m + h) - z(t_m)}{h} - f(t_m, z(t_m))$$

è chiamato errore di discretizzazione locale. Quando $\tau_m \rightarrow 0$ per $h \rightarrow 0$ il metodo è consistente.

$$\lim_{h \rightarrow 0} \frac{z(t_m + h) - z(t_m)}{h} = z'(t_m) \implies \lim_{h \rightarrow 0} \tau_m(h, f) = z'(t_m) - f(t_m, z(t_m)) = 0,$$

perché $f(t_m, z(t_m)) = z'(t_m)$. Quindi Euler esplicito è consistente. Inoltre, espandendo $z(t_m + h)$ con Taylor:

$$z(t_m + h) = z(t_m) + h z'(t_m) + \frac{h^2}{2} z''(t_m + \theta h), \quad \theta \in (0, 1).$$

Osservando $z'(t_m) = f(t_m, y_m) = f(t_m, z(t_m))$ si ha

$$\begin{aligned} I_m(h, f) &= z(t_{m+1}) - [y_m + h f(t_m, y_m)] \\ &= z(t_m + h) - z(t_m) - h z'(t_m) = \frac{h^2}{2} z''(t_m + \theta h). \end{aligned}$$

$$\boxed{\tau_m(h, f) = \frac{I_m(h, f)}{h} = \frac{h}{2} z''(t_m + \theta h)}, \quad |\tau_m(h, f)| \leq Mh, \quad M = \frac{1}{2} \max_{\theta \in (0, 1)} |z''(t_m + \theta h)|.$$

Nota (pagina 49): l'ultima riga manoscritta riporta $\tau(f, h) = O(h^2)$ e “metodo di ordine n ”; la pagina seguente precisa l'ordine corretto 1.

In questo caso $\tau(f, h) \propto h$, quindi $\tau = O(h^1)$: il metodo di Euler esplicito è di ordine 1.

2. Calcolo la tangente passante per il punto (t_m, y_m) e non per $(t_m, y(t_m))$. Questo contributo non è locale in quanto rappresenta l'accumulo di tutti gli errori di troncamento locale commessi in precedenza.

Non è garantito che questi errori tendano a zero quando $h \rightarrow 0$. In sintesi: non è detto che la convergenza a zero degli errori locali porti alla convergenza a zero dell'errore globale.

$$e(x) = 0 \quad \not\Longleftarrow \quad \tau_m(f, h) \rightarrow 0 \text{ con } h \rightarrow 0 \quad \forall m.$$

Il metodo è stabile se l'accumulo degli errori di troncamento locale si mantiene limitato per $h \rightarrow 0$.

Convergenza $\iff$ Stabilità + Consistenza
--