

Capitolo 7: Sincronizzazione



- Il problema della sincronizzazione.
- Il problema della sezione critica.
- Hardware per la sincronizzazione.
- Semafori.
- Problemi classici di sincronizzazione.
- Monitor (cenni).



Il problema della sincronizzazione



- L'accesso concorrente a dati condivisi può portare alla loro inconsistenza.
- Per mantenere la consistenza dei dati sono necessari dei meccanismi che assicurino l'esecuzione ordinaria di processi cooperanti che condividano uno spazio di indirizzi (codice e dati).
- Es.: in un sistema multithread, più thread cooperano mentre sono eseguiti in modo asincrono e condividono dati.
 - Possiamo esemplificare un paradigma di cooperazione come nel modello del produttore/consumatore.



Codice dei thread



Le chiamate del produttore:

```
while (count == BUFFER_SIZE)
   ; // non fare nulla
// aggiungi un elemento al buffer
++count;
buffer[in] = item;
in = (in + 1) % BUFFER SIZE;
```

Le chiamate del consumatore:

```
while (count == 0)
   ; // non fare nulla
// elimina l'elemento dal buffer
--count;
item = buffer[out];
out = (out + 1) % BUFFER SIZE;
```



Corse critiche



++count può essere implementata nel modo seguente:

```
register1 = count
register1 = register1 + 1
count = register1
```

count- - può essere implementata nel modo seguente:

```
register2 = count
register2 = register2 - 1
count = register2
```

Si consideri il seguente ordine di esecuzione. Supponiamo count=5:

```
S0: produttore esegue register1 = count {register1 = 5}
S1: produttore esegue register1 = register1 + 1 {register1 = 6}
S2: consumatore esegue register2 = count {register2 = 5}
S3: consumatore esegue register2 = register2 - 1 {register2 = 4}
S4: produttore esegue count = register1 {count = 6}
S5: consumatore esegue count = register2 {count = 4}
```

Il risultato dell'esecuzione non è universale ma dipende dall'ordine con cui si è dato accesso ai dati.



Il problema della sezione critica



- Primo metodo per garantire la regolamentazione degli accessi è dichiarare come critica la sezione di codice ad accesso condiviso.
- In un sistema costituito dagli n thread {T₀, T₁, ..., Tₙ-₁}, ogni thread potrà avere un segmento di codice determinato come critico.
- Soluzione al problema della sezione critica:
 - Mutua esclusione se il thread T_i sta eseguendo la sua sezione critica, nessun altro thread può eseguire la propria sezione critica.
 - 2. Progresso se nessun thread sta eseguendo la sua sezione critica e alcuni thread vogliono entrare nella loro, allora solo i thread che non stanno eseguendo la loro sezione non critica possono partecipare alla decisione su chi sarà il prossimo a entrare nella propria sezione critica, e questa scelta non può essere ritardata indefinitamente.
 - 3. Attesa limitata (bounded waiting) esiste un limite al numero di volte in cui gli altri thread possono entrare nelle loro sezioni critiche dopo che un thread ha fatto richiesta di entrare nella propria e prima che tale richiesta sia esaudita. Prevenzione della starvation di un singolo thread.
 - Assumiamo che ciascun thread sia in esecuzione a velocità non nulla.
 - Non si può fare alcuna ipotesi sulle velocità relative degli n thread.



Soluzione software



- Si presenta complessa e spesso inefficiente anche nel caso di sistemi semplici (pochi thread).
- Tutte le soluzioni software sono generalmente basate su di un algoritimo di ordinamento. Generalmente allo scopo si adopera l'algoritmo di Bakery.
- Si impone l'accesso alle sezioni critiche dei processi secondo uno stringente paradigma di tipo FCFS.

ALGORITMO DI BAKERY

- Si ipotizzi l'accesso alla sezione critica per n generici thread.
- Prima di fare ingresso alla sezione critica, ciascun thread riceve un token numerico. Il thread possessore del token di valore più basso accede alla propria sezione critica.
- Se due thread Ti and Tj ricevono il medesimo token, se i < j, allora Ti riceve la precedenza; in caso contrario la riceve Tj.
- Lo schema di generazione algoritmica dei token genera sempre una sequenza crescente, *p.es.*: 1,2,3,3,3,4,5...



Hardware per la sincronizzazione



- Molti sistemi forniscono istruzioni hardware per la risoluzione del problema della sezione critica.
- Monoprocessori: si possono disabilitare gli interrupt durante l'accesso alle sezioni critiche.
 - La sequenza di istruzioni corrente sarà eseguita in ordine senza interruzioni.
- Di solito troppo inefficiente sui sistemi multiprocessore (i comandi per la disabilitazione degli interrupt devono essere passati a tutti i processori).
 - Ritardo nell'accesso alle sezioni critiche e nell'uscita da esse.
 - I sistemi operativi che lo usano sono carenti in scalabilità quando vengono aggiunte CPU.
 - ▶ I costi computazionali ed i ritardi aumentano al crescere delle CPU
- I calcolatori moderni forniscono istruzioni hardware speciali che funzionano in modo atomico.
 - ▶ Atomico = non-interrompibile.
 - Controllare e modificare il contenuto di una parola di memoria.
 - Scambiare il contenuto di due parole.



Semafori



- Sebbene efficaci, le soluzioni hardware sono di uso complesso per i programmatori di applicazioni.
- Strumenti poco complessi di sincronizzazione che impongono iterativamente un blocco durante un'attesa in modo attivo (spin lock).
- Semaforo S variabile intera.
- Dopo l'inizializzazione si può accedere ad un semaforo S solo tramite due operazioni: acquire() e release().
- Si tratta di due operazioni indivisibili (le modifiche al valore intero di S sono permesse da un solo thread per volta):

Nella acquire(S) il test sul valore positivo di S e la sua possibile modifica devono essere eseguiti senza interruzioni.



Impiego



- Semaforo generalizzato il valore può variare in un dominio senza restrizioni.
- Semaforo binario il valore può essere solo 0 o 1; può essere più facile da implementare.
 - Noto anche come mutex lock perchè consente di gestire la mutua esclusione.

```
Semaphore S; // assumo S inizializzato a 1
acquire(S);
criticalSection();
release(S);
```

- Possiamo adoperare semafori per controllare l'accesso a sezioni critiche.
- Si può adoperare un semaforo generalizzato S per controllare l'accesso ad una risorsa con un numero finito di istanze.
 - S viene inizializzato al numero di istanze della risorsa disponibili.
 - Un thread che desidera accedere alla risorsa esegue una acquire() su S (decrementando il contatore).
 - Un thread che rilascia la risorsa esegue una release() (incrementando il counter).
 - Quando S=0, tutte le istanze sono allocate e i thread che richiedano la risorsa resteranno in attesa del rilascio di un esemplare di essa.



Implementazione di semafori (1/2)



- Semafori come quelli descritti (spinlock) hanno lo svantaggio del busy waiting.
 - Mentre un processo è nella propria sezione critica, ogni altro processo che prova ad accedere alla propria deve ciclare continuamente sprecando cicli di CPU che potrebbero essere sfruttati da altri processi.
 - Gli spinlock non obbligano a cambi di contesto pertanto tornano utili quando si prevede che i blocchi vengano tenuti per brevi periodi (sistemi multiprocessore).

```
acquire(S) {
    S--;
    if (S < 0) {
            add the process to list;
            block;
    }
}
release(S) {
    S++;
    if (S <= 0) {
            remove a process P from list;
            wakeup(P);
    }
}</pre>
```

- Per superare il busy waiting si ridefiniscono acquire() e release().
 - Una acquire() che trova una variabile semaforica negativa mette il thread in una coda di attesa associata al semaforo.
 - Il microscheduler seleziona un altro processo da eseguire.
 - Un processo bloccato viene risvegliato da un wake-up a seguito di una release() di un altro processo sul semaforo.
 - Dopo il wake-up il thread bloccato viene rimosso dalla coda del semaforo e riposizionato nella coda di ready.
- I semafori dovranno così essere definiti come coppia variabile semaforica (intero) e coda di attesa.



Implementazione di semafori (2/2)



- Il semaforo può così assumere anche valori negativi.
 - Il valore assoluto rappresenta il numero di processi in coda di attesa.
- La lista d'attesa è implementata mediante due puntatori alla testa ed alla fine di una coda FIFO di PCB.
- Deve garantire che due processi non possano eseguire una acquire() ed una release() sullo stesso semaforo nello stesso momento. Questa situazione genera un problema di sezione critica.
 - Soluzione:
 - Ambiente monoprocessore: inibire gli interrupt durante l'esecuzione di acquire() e release().
 - Ambiente multiprocessore: adoperare istruzioni hardware speciali o adottare soluzioni software per la sezione critica.
- acquire() e release() non evitano il busy waiting ma lo dirottano nelle rispettive sezioni critiche dei programmi applicativi.
 - Queste sezioni sono brevi pertanto l'attesa attiva avviene raramente e quando capita è solo per brevi periodi.
 - Le applicazioni invece possono impiegare molto tempo nelle sezioni critiche ed in tal caso l'attesa attiva è estremamente svantaggiosa.



Stalli e starvation



- Stallo (deadlock) due o più processi aspettano un evento che può essere causato solo da uno dei processi in attesa (nel caso dei semafori l'evento in questione è una release()).
- Consideriamo un sistema costituito da due processi P ciascuno dei quali accede a due semafori S e Q valorizzati a 1.

```
P_0 P_1 acquire(S); acquire(Q); acquire(S); . . . . . . . . release(S); release(Q); release(S);
```

- Blocco indefinito (starvation) i processi attendono indefinitamente all'interno del semaforo. Un processo può non essere mai rimosso dalla coda del semaforo nella quale è sospeso.
 - Può verificarsi se la coda semaforica di attesa è organizzata secondo il criterio LIFO.



Monitor



- Benché i semafori forniscano un meccanismo conveniente ed efficace per la sincronizzazione, il loro utilizzo non corretto comporta errori di temporizzazione difficilmente individuabili.
 - Essi avvengono in modo asincrono solo in determinate sequenze di esecuzione.
- Un monitor è un costrutto in un linguaggio ad alto livello che provvede alla sincronizzazione di thread.
 - Il tipo monitor è un tipo di dato astratto che incapsula metodi pubblici per l'esecuzione di operazioni su dati privati.
 - Un tipo monitor presenta operazioni definite dall'utente su cui è fornita la mutua esclusione: solo un thread per volta può essere attivo in un monitor.
 - Il tipo monitor contiene:
 - La dichiarazione di variabili mediante le quali si definisce lo stato dell'istanza.
 - Le funzioni/procedure che operano sulle variabili stesse.

```
monitor monitor-name
   shared variable declarations
   public entry p1(...) {
   public entry p2(...) {
    public entry pN(...) {
       initialization code
```



Le variabili di tipo condition



- I thread non possono accedere direttamente all'implementazione interna di un monitor.
- Solo le procedure definite internamente al monitor possono accedere alle variabili locali o a quelle condivise.
- Il costrutto del monitor proibisce l'accesso concorrente alle procedure interne. Il programmatore non deve codificare la sincronizzazione esplicitamente.
- Le variabili di tipo *condition* (x e y nell'esempio) e i metodi *wait* e *signal* implementano la sincronizzazione;
- Un thread che invoca x.wait è sospeso finchè un altro thread non invoca x.signal.

