

Autoencoder

per l'apprendimento non supervisionato in
reti neurali profonde

Finora abbiamo descritto l'applicazione delle reti neurali all'apprendimento supervisionato (**supervised learning**), in cui abbiamo etichettato esempi di addestramento.


Ora supponiamo di avere solo esempi di addestramento non etichettati :

$\{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \dots\}$, dove $\mathbf{x}_i \in \mathbb{R}^n$

Una rete neurale **autoencoder** utilizza un **algoritmo di apprendimento non supervisionato (unsupervised learning)** che applica la backpropagation, impostando i valori target in modo che siano uguali all'input.

Vale a dire, utilizza $\mathbf{y}_i = \mathbf{x}_i$.

Esempio di un autoencoder



Input
(Features I)

Features II
(Nascosto)

Output

L'autoencoder cerca di apprendere la funzione identità

$$h(x) = x$$

imponendo dei vincoli alla rete, ad esempio:

1. Limitando il numero di unità nascoste, possiamo scoprire cose interessanti (**vincolo di densità**)
2. Lasciare che il numero di unità nascoste sia grande (maggiore del numero di pixel di input) (**vincolo di sparsità**)

Ciò li aiuta ad apprendere **strutture interessanti** nei dati.

Visualizzazione

Dopo aver addestrato un autoencoder, vorremmo ora visualizzare la funzione appresa dall'algoritmo, per cercare di capire cosa ha imparato.


Consideriamo il caso di addestramento di un autoencoder su immagini 10×10 , in modo che $n = 100$. Ogni unità nascosta i calcola una funzione dell'input:

$$a_i^{(2)} = f \left(\sum_{j=1}^{100} W_{ij}^{(1)} x_j + b_i^{(1)} \right)$$

Visualizzazione (2)

Quando eseguiamo questa operazione per un **autoencoder sparso** (addestrato con 100 unità hidden su input di 10x10 pixel) otteniamo il seguente risultato:


(Ogni riquadro rappresenta l'immagine che attiva al massimo quel neurone.)




Autoencoder impilati (profondi)

L'impilamento di layer di autoencoder produce un'architettura più profonda nota come Stacked o Deep Autoencoder.

Applicazioni: riconoscimento facciale, riconoscimento vocale, eliminazione del rumore dal segnale, ecc.



Apprendimento in Stacked Autoencoders




In genere, gli autoencoder vengono **impilati** uno sull'altro per apprendere caratteristiche complesse dai dati.

L'**algoritmo di backpropagation** viene applicato anche per l'apprendimento negli autoencoder. L'unica differenza è che l'apprendimento avviene tramite **pretraining** di ogni layer prima del suo **successore**.

Pretraining: Stacked Denoising Auto-encoder

- Stacking Auto-Encoders



from: Bengio ICML 2009

Denoising autoencoders: per forzare l'hidden layer a scoprire feature più robuste e impedirgli di apprendere semplicemente l'identità, addestriamo l'autoencoder a ricostruire l'input da una versione corrotta dello stesso.

Autoencoder di denoising

L'immagine mostra come un **autoencoder di "denoising"** può essere utilizzato per generare un input corretto da un input corrotto.




input corrotto

input pulito


Esempio 1: Riconoscimento facciale

FACIAL RECOGNITION


Deep-learning neural networks use layers of increasingly complex rules to categorize complicated shapes such as faces.



Layer 1: The computer identifies pixels of light and dark.



Layer 2: The computer learns to identify edges and simple shapes.



Layer 3: The computer learns to identify more complex shapes and objects.



Layer 4: The computer learns which shapes and objects can be used to define a human face.


Esempio 2: Recupero di documenti

(rappresentazione e classificazione delle informazioni)

Possiamo utilizzare un autoencoder per trovare rappresentazioni a bassa dimensionalità per documenti che consentano il recupero rapido e accurato di documenti simili da un set di grandi dimensioni.

Iniziamo convertendo ogni documento in un "bag of words". Questo è un **vettore a 2000 dimensioni** che contiene i conteggi per ciascuna delle 2000 parole più comuni.

Come comprimere il vettore di conteggio




Addestriamo la rete neurale a riprodurre il suo vettore di input come output

Ciò lo costringe a comprimere quante più informazioni possibili nei 10 numeri del collo di bottiglia centrale.

Questi 10 numeri rappresentano quindi un buon modo per confrontare i documenti.

Utilizzo di autoencoder per visualizzare i documenti

Invece di utilizzare rappresentazioni per recuperare documenti, possiamo utilizzare rappresentazioni 2D per visualizzare serie di documenti.




Utilizzo della PCA

(analisi dei componenti principali)

Comprimere tutti i documenti in 2 numeri utilizzando un tipo di PCA


Quindi utilizzare colori diversi per le diverse categorie di documenti



Utilizzo degli autoencoder

Comprimi tutti i documenti in 2 numeri con un autoencoder. Quindi usa colori diversi per le diverse categorie di documenti

Autoencoder 2-D Topic Space



Un modo davvero veloce per trovare documenti simili

- Supponiamo di poter **convertire ogni documento in un vettore di caratteristiche binario** in modo tale che documenti simili abbiano vettori di caratteristiche simili.
- Ciò crea uno spazio di indirizzamento “semantico” che ci consente il recupero.
- Dato un documento di query, **utilizziamo prima l'autoencoder per calcolare il suo indirizzo binario**.
- Quindi **recuperiamo** tutti i documenti dagli indirizzi che si trovano entro un piccolo **raggio nello spazio di Hamming**.
- Ciò richiede tempo **costante**. Non sono richiesti confronti per ottenere la lista ristretta di documenti semanticamente simili.